2025.12.9. 多元函数微分.

1. 偏导数.

$f(x,y)$. 将 y 视为常数，仅对 x 求导 $\Rightarrow f_x(x,y)$. 称为 f 关于 x 的偏导数. 也记作 f_1, $\frac{\partial f}{\partial x}$.

f_x 是关于 x,y 二元函数，还可以继续求偏导.

如 $f_{xy} = \frac{\partial^2 f}{\partial y \partial x} = \frac{\partial}{\partial y}\left(\frac{\partial f}{\partial x}\right)$. $f_{xx} = \frac{\partial^2 f}{\partial x^2} = \frac{\partial}{\partial x}\left(\frac{\partial f}{\partial x}\right)$ 等

Rmk. f_{xy} 和 f_{yx} 不一定相等.

Eg. ① $f = \tan\frac{x^2}{y}$. 求 $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$

$$\frac{\partial f}{\partial x} = \sec^2\frac{x^2}{y}\cdot\frac{2x}{y}, \quad \frac{\partial f}{\partial y} = \sec^2\frac{x^2}{y}\cdot\left(-\frac{x^2}{y^2}\right).$$

② $g = \arcsin\frac{x}{\sqrt{x^2+y^2}}$ 求 $\frac{\partial g}{\partial x}$, $\frac{\partial g}{\partial y}$.

$$\frac{\partial g}{\partial x} = \frac{1}{\sqrt{1-\frac{x^2}{x^2+y^2}}}\cdot\frac{\sqrt{x^2+y^2}-\frac{x^2}{\sqrt{x^2+y^2}}}{x^2+y^2} = \frac{1}{\sqrt{\frac{y^2}{x^2+y^2}}}\cdot\frac{1}{x^2+y^2}\cdot\frac{y^2}{\sqrt{x^2+y^2}} = \frac{y}{x^2+y^2}\cdot\mathrm{sgn}(y).$$

$$\frac{\partial g}{\partial y} = \frac{1}{\sqrt{\frac{y^2}{x^2+y^2}}}\cdot\frac{-x\cdot\frac{y}{\sqrt{x^2+y^2}}}{x^2+y^2} = -\frac{y}{x^2+y^2}\cdot\mathrm{sgn}(y).$$

③ $u(x,y) = e^x\cos y$, $v(x,y) = e^x\sin y$.

求证: $\frac{\partial u}{\partial x} = \frac{\partial v}{\partial y}$, $\frac{\partial u}{\partial y} = -\frac{\partial v}{\partial x}$.

证明: $\frac{\partial u}{\partial x} = e^x\cos y$, $\frac{\partial v}{\partial y} = e^x\cos y$

$\frac{\partial u}{\partial y} = -e^x\sin y$ $\frac{\partial v}{\partial x} = e^x\sin y$.

Rmk. 这称为 Cauchy-Riemann 方程. 这样的 u,v 称为共轭调和函数

定义 $f(x+iy) = u(x,y) + i\cdot v(x,y)$. 会使 f 是复解析函数.

本例中对应 $f(x+iy) = e^{x+iy}$.

④ $f(x,y)=\begin{cases}0, & xy=0\\ 1, & xy\neq 0.\end{cases}$ 求 $f_x(0,0)$, $f_y(0,0)$

$\frac{\partial f}{\partial x}(0,0)=\frac{\partial f}{\partial y}(0,0)=0.$

但是注意到 f 在 $(0,0)$ 处甚至无极限.

可见偏导数是极弱的概念.

偏可导对函数光滑性要求非常低.

2. 方向导数 ~~和方向~~.

类比偏导数，可以在各个方向上定义"偏导数"，而不一定局限于 x,y 轴方向.

Def. 定义 f 在 v 方向的方向导数

$$\frac{\partial f}{\partial v}(x_0)=\lim_{t\to 0^+}\frac{f(x_0+tv)-f(x_0)}{t}\qquad (|v|=1).$$

Eg. ① $f(x,y)=\sqrt{x^2+y^2}$. 在 $(0,0)$ 处 $\frac{\partial f}{\partial v}$? $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$ 存在吗?

记 $v=(\cos\theta,\sin\theta)$

$$\frac{\partial f}{\partial v}(0,0)=\lim_{t\to 0^+}\frac{\sqrt{t^2\cos^2\theta+t^2\sin^2\theta}-0}{t}=1.$$

$\frac{\partial f}{\partial x}$ 不存在. 因为 $\lim_{x\to 0^+}\frac{f(x,0)-0}{x}=1$

$\lim_{x\to 0^-}\frac{f(x,0)-0}{x}=-1$

同理 $\frac{\partial f}{\partial y}$ 不存在.

Rmk. 区分"方向导数"和"偏导数".

方向导数是单侧的，偏导数是双侧的.

② $f(x,y)=\begin{cases}1, & y=x^2 \text{ 且 } x\neq 0\\ 0, & \text{其它}.\end{cases}$ 求 $\frac{\partial f}{\partial v}(0,0)$.

显然 $\forall v\in\mathbb{R}^2$. $\exists \delta>0$. s.t. $\forall 0<t<\delta$. 有 $f(tv)=0$.

故 $\frac{\partial f}{\partial v}(0,0)=0$. $\forall v\in\mathbb{R}^2$.

但 f 在 $(0,0)$ 甚至没有极限.

3. 全微分

回忆一元导数，那里我们定义了"可微".

如果 $f(x_0+\Delta x)-f(x_0)=A\Delta x+o(\Delta x)$. $\Delta x\to 0$.

就称 f 在 x_0 处可微. $A\Delta x$ 是微分. 记作 $df=A\,dx$.

我们类似定义多元函数可微性.

Def. 如果 $f(x_0+\Delta x)-f(x_0)=(A_1,\dots,A_n)\begin{pmatrix}\Delta x_1\\ \vdots\\ \Delta x_n\end{pmatrix}+o(|\Delta x|)$. $|\Delta x|\to 0$.

就称 n 元函数 f 在 x_0 处可微. $\underbrace{\sum_{i=1}^n A_i\Delta x_i}$ 称为全微分.

也记作 $df=A^T dx$.

$A_i dx_i$ 称为沿向上偏微分.

Eg. $f(x,y)=\begin{cases}(x^2+y^2)\sin\frac{1}{x^2+y^2}, & x^2+y^2\neq 0\\ 0, & x^2+y^2=0.\end{cases}$

(1) 验证 f 在 $(0,0)$ 连续.

证明: $|f|\le|x^2+y^2|\to 0$ $((x,y)\to(0,0))$ □.

(2) 求 f 在 $(0,0)$ 全微分.

注意到 $f(x,y)-f(0,0)=(x^2+y^2)\sin\frac{1}{x^2+y^2}=o(\sqrt{x^2+y^2})$. $((x,y)\to(0,0))$

故 $df=0$.

(3) 求 f_x, f_y. f_y 类似

$x^2+y^2\neq 0$ 时, $f_x(x,y)=2x\sin\frac{1}{x^2+y^2}-\frac{2x}{(x^2+y^2)}\cos\frac{1}{x^2+y^2}$

$x^2+y^2=0$ 时, $f_x(0,0)=0$

Rmk. 在 $(0,0)$. f_x 不连续.

4. 基础线性代数.

① 作为线性函数 $y=kx$. 在多元函数上的推广.

$$f(x_1, x_2, \cdots, x_n) = a_1x_1 + a_2x_2 + \cdots + a_nx_n.$$

其满足 $\begin{cases} ① \text{ 加性 } f(x_1+y_1, x_2+y_2, \cdots, x_n+y_n) = f(x_1, \cdots, x_n) + f(y_1, \cdots, y_n) \\ ② \text{ 齐性. } f(kx_1, \cdots, kx_n) = kf(x_1, \cdots, x_n). \end{cases}$

统称为线性性.

② 线性映射.

考虑. $f: \mathbb{R}^n \to \mathbb{R}^m$ 是多元映射. 且线性.

即 $\begin{cases} \begin{pmatrix} f_1(x+y) \\ \vdots \\ f_m(x+y) \end{pmatrix} = \begin{pmatrix} f_1(x) \\ \vdots \\ f_m(x) \end{pmatrix} + \begin{pmatrix} f_1(y) \\ \vdots \\ f_m(y) \end{pmatrix}. \\ \begin{pmatrix} f_1(kx) \\ \vdots \\ f_m(kx) \end{pmatrix} = k\begin{pmatrix} f_1(x) \\ \vdots \\ f_m(x) \end{pmatrix}. \end{cases}$

或写成向量形式 $\begin{cases} f(x+y) = f(x) + f(y) \\ f(kx) = kf(x). \end{cases}$

这里 $x, y \in \mathbb{R}^n$, $f(x) \in \mathbb{R}^m$, $k \in \mathbb{R}$.

这种映射称为线性映射, 是最简单的连续映射.

③ 矩阵和转置

一个矩阵是指一个 $m \times n$ 数表 $A \in \mathbb{R}^{m\times n}$

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}.$$

转置: $A^T = \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{m1} \\ \vdots & & & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{mn} \end{pmatrix} \in \mathbb{R}^{n\times m}$.

向量也是矩阵. $a=(a_1,a_2,\cdots,a_n)\in\mathbb{R}^{1\times n}$ 称为行向量

$x=\begin{pmatrix}x_1\\ \vdots\\ x_n\end{pmatrix}=(x_1,\cdots,x_n)^T\in\mathbb{R}^{n\times 1}$ 称为列向量

列向量也简记为 $\in\mathbb{R}^n$.

一般默认向量为列向量.

④ 矩阵的加和~~乘~~数乘.

加法: 如果 $A,B\in\mathbb{R}^{m\times n}$.

定义 $A+B=\begin{pmatrix}a_{11}+b_{11} & \cdots & a_{1n}+b_{1n}\\ \vdots & & \vdots\\ a_{m1}+b_{m1} & \cdots & a_{mn}+b_{mn}\end{pmatrix}$.

~~②~~数乘: $A\in\mathbb{R}^{mn}$, $k\in\mathbb{R}$

定义 $kA=\begin{pmatrix}ka_{11} & \cdots & ka_{1n}\\ \vdots & & \vdots\\ ka_{m1} & \cdots & ka_{mn}\end{pmatrix}$.

⑤ 内积、矩阵乘向量、矩阵乘法.

(1) 内积 $a,b\in\mathbb{R}^n$.

$a\cdot b=a^Tb=\sum_{i=1}^n a_ib_i$

如果把A写成 $\begin{pmatrix}a_1^T\\ a_2^T\\ \vdots\\ a_m^T\end{pmatrix}$.

则 $Ax=\begin{pmatrix}a_1^Tx\\ a_2^Tx\\ \vdots\\ a_m^Tx\end{pmatrix}$.

(2) 矩阵乘向量. $A\in\mathbb{R}^{m\times n}$, $x\in\mathbb{R}^n$.

定义 $Ax=\begin{pmatrix}a_{11} & \cdots & a_{1n}\\ \vdots & & \vdots\\ a_{m1} & \cdots & a_{mn}\end{pmatrix}\begin{pmatrix}x_1\\ \vdots\\ x_n\end{pmatrix}=\begin{pmatrix}\sum_{j=1}^n a_{1j}x_j\\ \sum_{j=1}^n a_{2j}x_j\\ \vdots\\ \sum_{j=1}^n a_{mj}x_j\end{pmatrix}\in\mathbb{R}^m$.

即 Ax 的第k分量, 是A的第k行和x做内积.

(3) 矩阵乘法. $A\in\mathbb{R}^{m\times n}$, $B\in\mathbb{R}^{n\times s}$

定义. $C=AB\in\mathbb{R}^{m\times s}$. $C_{ij}=\sum_{k=1}^n A_{ik}B_{kj}$

即 C_{ij} 是A第i行和B第j列做内积.

把A,B写作 $\begin{pmatrix}a_1^T\\ \vdots\\ a_m^T\end{pmatrix}$ 和 $(b_1,\cdots,b_s)$, 则 $AB=(Ab_1,Ab_2,\cdots,Ab_s)=\begin{pmatrix}a_1^Tb_1 & a_1^Tb_2 & \cdots & a_1^Tb_s\\ \vdots & & & \vdots\\ a_m^Tb_1 & a_m^Tb_2 & \cdots & a_m^Tb_s\end{pmatrix}$

⑥ 线性映射均可用矩阵乘向量表示.

Eg. (1) $y = a_1x_1 + a_2x_2 + \cdots + a_nx_n = a^TX$.

(2) 多元线性映射: $\underset{\in\mathbb{R}^n}{f(x)} = \begin{pmatrix} a_1^TX \\ a_2^TX \\ \vdots \\ a_m^TX \end{pmatrix} \in \mathbb{R}^m$.

$$= \begin{pmatrix} a_1^T \\ a_2^T \\ \vdots \\ a_m^T \end{pmatrix} X = \overset{\in\mathbb{R}^{m\times n}}{A}X$$

这样就与 $y=Kx$ 统一了形式.

Eg. 全微分. $df = A^Tdx$ $\quad A = \begin{pmatrix} A_1 \\ \vdots \\ A_n \end{pmatrix}$.

回忆一元函数我们说微分是线性近似.

对多元情形, 实际上也是用线性映射近似可微映射.

另外, 我们知道 $A_i = \frac{\partial f}{\partial x_i}$. 因此一般定义 $\nabla f = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}$.

称为梯度 (gradient).

这才是高维的导数. 满足 $df = \nabla f^T dx$.

即 $f(x_0+\Delta x) = f(x_0) + \nabla f(x_0)^T\Delta x + o(|\Delta x|)$.

即一阶 Taylor 展开.

意义为在 x_0 附近, 用超平面

$y = f(x_0) + \nabla f(x_0)^T\Delta x$ 近似 $f(x)$.

⑦ 二次型

作为二次函数 $y = ax^2+bx+c$ 的高维形式.

$$a_{11}x^2 + a_{22}y^2 + \cancel{a_{12}xy + a} \underset{(a_{12}+a_{21})xy}{} = (x, y)\begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}\begin{pmatrix} x \\ y \end{pmatrix}$$

请自行用矩阵乘法加以验证.

可以进一步要求 $a_{12}=a_{21}$ $(a_{ij}=a_{ji})$

则 $a_{11}x^2+2a_{12}xy+a_{22}y^2+b_1x+b_2y+C$

$$=(x,y)\begin{pmatrix}a_{11} & a_{12}\\ a_{21} & a_{22}\end{pmatrix}\begin{pmatrix}x\\ y\end{pmatrix}+(b_1,b_2)\begin{pmatrix}x\\ y\end{pmatrix}+C.$$

$\mathbb{R}^n$中二次函数具有类似以上的一般形式.

$$f(x)=\frac{1}{2}x^TAx+b^Tx+C.$$

其中, x^TAx 称为二次型 (Quadratic form).

因此可以猜测, Taylor公式 $f(x)=f(x_0)+f'(x_0)(x-x_0)+\frac{1}{2}f''(x_0)(x-x_0)^2+o((x-x_0)^2)$.

会推广为形如 $f(x)=f(x_0)+\nabla f(x_0)^T(x-x_0)+\frac{1}{2}(x-x_0)^TA(x-x_0)+o(|x-x_0|^2)$.

其中A是二阶导的推广.

$A=$ ~~$\frac{\partial x\partial x}{}$~~ $A_{ij}=\frac{\partial^2 f}{\partial x_i\partial x_j}$. 称为Hessi矩阵.

也记作 $\nabla^2 f$.

⑧ 行列式.

对 $A\in\mathbb{R}^{n\times n}$ 可以定义其行列式 $|A|$

$|A|\neq 0$. 表示线性映射 $y=Ax$ 是可逆的. (Cramer法则).

类比一元情形. 把 f 在 x_0 处展开. $f(x)\approx f(x_0)+f'(x_0)(x-x_0)$

$f'(x_0)\neq 0$.

则 f 在 x_0 局部可逆.

$\nabla f\in\mathbb{R}^{n\times n}$. $(\nabla f)_{ij}=\frac{\partial f_i}{\partial x_j}$

在高维情形. $f(x)\approx f(x_0)+\nabla f(x_0)(x-x_0)$

$(\mathbb{R}^n\to\mathbb{R}^n)$

如果 $|\nabla f(x_0)|\neq 0$. 则 f 在 x_0 局部可逆 (逆映射定理).

(*)向量函数/多元映射全微分.

$$f: \mathbb{R}^n \to \mathbb{R}^m. \quad \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \mapsto \begin{pmatrix} f_1 \\ \vdots \\ f_m \end{pmatrix}.$$

一个向量 $\in \mathbb{R}^m$

每个分量都是 $o(|\Delta x|)$

如果 $\exists A \in \mathbb{R}^{m\times n}$ s.t. $\Delta f(x_0) = A\Delta x + o(|\Delta x|)$

就称 $df = A\,dx$. $A\,dx$ 是全微分.

A 称为 f 的 Jacobian / 雅各比矩阵

本质即用线性映射 Ax 近似 $f(x)$.

其中, $|A|$ 即一元时, $f'(x)$ 的推广. (m=n时) 也记 $A = \dfrac{\partial(f_1,\cdots,f_n)}{\partial(x_1,\cdots,x_n)}$.

一元积分换元时, $\int f(x)\,dx = \int f(x(t))\,x'(t)\,dt$

高维时推广为, $\int f(x)\,dx = \int f(x(t))\left|\dfrac{\partial(x_1,\cdots,x_n)}{\partial(t_1,\cdots,t_n)}\right| dt$.

因此经常需要计算 Jacobian 行列式.

Eg. ① $f: \begin{pmatrix} r \\ \theta \end{pmatrix} \mapsto \begin{pmatrix} r\cos\theta \\ r\sin\theta \end{pmatrix}$.

$$\frac{\partial(x,y)}{\partial(r,\theta)} = \begin{pmatrix} \frac{\partial x}{\partial r} & \frac{\partial x}{\partial \theta} \\ \frac{\partial y}{\partial r} & \frac{\partial y}{\partial \theta} \end{pmatrix} = \begin{pmatrix} \cos\theta & -r\sin\theta \\ \sin\theta & r\cos\theta \end{pmatrix}.$$

$$\left|\frac{\partial(x,y)}{\partial(r,\theta)}\right| = r.$$

② $f: \begin{pmatrix} r \\ \varphi \\ \theta \end{pmatrix} \mapsto \begin{pmatrix} r\sin\varphi\cos\theta \\ r\sin\varphi\sin\theta \\ r\cos\varphi \end{pmatrix}$.

$$\frac{\partial(x,y,z)}{\partial(r,\varphi,\theta)} = \begin{pmatrix} x_r & x_\varphi & x_\theta \\ y_r & y_\varphi & y_\theta \\ z_r & z_\varphi & z_\theta \end{pmatrix} = \begin{pmatrix} \sin\varphi\cos\theta & r\cos\varphi\cos\theta & -r\sin\varphi\sin\theta \\ \sin\varphi\sin\theta & r\cos\varphi\sin\theta & r\sin\varphi\cos\theta \\ \cos\varphi & -r\sin\varphi & 0 \end{pmatrix}.$$

$$\left|\frac{\partial(x,y,z)}{\partial(r,\varphi,\theta)}\right| = r^2\sin\varphi.$$